

Modelo de Deserción en Educación Superior

Kevin Snaider Sanchez Prieto, Jorge Alberto Gómez Vigoya

Carol Johana Peña Pico, Elizabeth Lorena Porras Ortiz

Resumen

Actualmente, Colombia enfrenta un desafío crítico en su sistema de educación superior: tasas de deserción estudiantil que superan el 45% (SPADIES, 2025), afectando el desarrollo de capital humano y la eficiencia del gasto público. Aunque el Plan Nacional de Desarrollo 2022–2026 establece metas para mejorar la cobertura y permanencia educativa, no existe una herramienta analítica que permita identificar los factores asociados a la deserción ni generar alertas tempranas efectivas. Esta brecha representa una oportunidad para desarrollar un modelo predictivo, que integre técnicas de *machine learning* (como Random Forest o XGBoost) y análisis de datos socioeconómicos y académicos, con el fin de clasificar el riesgo de deserción (bajo, medio, alto) y facilitar intervenciones focalizadas. El proyecto se implementará en instituciones de educación superior, utilizando datos del SPADIES, DANE e ICFES, y buscará reducir la deserción en al menos un 5%, optimizar la asignación de recursos y fortalecer la toma de decisiones basada en evidencia. La metodología incluirá fases de diagnóstico, modelado, validación y despliegue de un *dashboard* interactivo, priorizando regiones con diversidad socioeconómica para garantizar la escalabilidad y pertinencia de la solución.

Palabras claves: Deserción estudiantil, educación superior, modelo predictivo, machine learning, alertas tempranas, análisis de datos, equidad educativa, dashboards interactivos.

Índice

1. Introducción.....	3
2. Estado del arte en las investigaciones del área.....	3
a. José Leonardo Pérez Niño, Oscar Eduardo Gualdrón Guerrero, Diego José Barrera Oliveros. (2024-2025). SciELO, Recuperado de: Modelos de inteligencia artificial en minería de datos educativos para predecir la deserción.....	4
b. David Núñez Villalobos. (2025). Modelo Predictivo basado en Aprendizaje Automático para la Retención Estudiantil. EPSIR, Chile. Recuperado de: Modelo Predictivo basado en Aprendizaje Automático para la retención Estudiantil.....	4
c. Pontificia Universidad Javeriana. (2023). Deserción en la educación superior en Colombia: Informe de resultados. Bogotá, Colombia. Recuperado de: Deserción en la educación superior en Colombia.....	5
d. Pontificia Universidad Javeriana Cali. (2021). Un enfoque predictivo con Machine Learning para mejorar la retención estudiantil. Cali, Colombia. Recuperado de: UN ENFOQUE PREDICTIVO CON MACHINE LEARNING PARA MEJORAR LA RETENCIÓN.....	5
e. Universidad del Magdalena. (2025). Sistema de predicción basado en machine learning de la deserción académica. Santa Marta, Colombia. Recuperado de: Sistema de predicción basado en machine learning de la deserción académica.....	5
Tabla 1. Resumen de estudios previos sobre deserción en educación superior. Fuente: Autoría propia... 6	6
Relación con el Proyecto Actual.....	6
3. Desarrollo del proyecto.....	7
Figura 1. Fases del proyecto: De la inicialización al cierre para reducir la deserción en educación superior. Fuente: Autoría propia.....	7
3.1. Inicialización.....	7
Contexto y Planteamiento del Problema.....	7
Alcance y Solución Propuesta.....	8
Definición de Métricas de Éxito.....	8
Identificación de Recursos y Stakeholders.....	8
3.2 Fase Analizar y Diseñar: Planificación.....	9
Análisis de Riesgos (RBS y AMEF).....	9
Análisis de Datos y Dimensiones de Calidad.....	9
Cronograma y Asignación de Responsabilidades.....	10
Enfoque de Modelación.....	10
3.3. Fase Configuración y Construcción: Ejecución.....	10
Selección y Justificación de Modelos y Técnicas.....	10
Procesamiento de Datos.....	11
Métricas de Ejecución como Insumo para Monitoreo y Control.....	11
Desarrollo del Dashboard de Alertas.....	11
3.4. Fase Operación, Optimización y Despliegue: Monitoreo y Control.....	11
Sinergia entre Ejecución y Monitoreo.....	11
Herramientas y Mecanismos de Control (El "Cómo").....	12
Validación de Técnicas y Evaluación de Beneficios.....	12
Optimización y Cierre del Ciclo.....	12
3.5. Fase de Cierre.....	12
Presentación de Resultados y Concordancia Analítica.....	13
Procesos de Entrenamiento y Transferencia de Conocimiento.....	13
Proceso de Implementación Final y Escalamiento.....	13
Evaluación de Satisfacción de los Interesados.....	13
4. Referencias.....	14

1. Introducción

La deserción en la educación superior en Colombia representa uno de los desafíos más críticos para el desarrollo social y económico del país. Según datos del Sistema para la Prevención de la Deserción en la Educación Superior (SPADIES, 2025), la tasa promedio de deserción acumulada supera el 45%, una cifra que no solo compromete la formación de capital humano, sino que también implica una pérdida significativa de recursos públicos y obstaculiza el cumplimiento de los objetivos del Plan Nacional de Desarrollo 2022–2026. Este plan, sustentado en siete pilares estratégicos, busca mejorar la cobertura, equidad y permanencia educativa, pero enfrenta un rezago crítico: no existe una herramienta analítica que permita identificar los factores asociados a la deserción ni generar alertas tempranas efectivas. Aunque el Ministerio de Educación Nacional (MEN) ha avanzado en políticas de gratuidad y sistemas integrados de educación, la falta de un modelo predictivo basado en inteligencia artificial limita la capacidad de las instituciones para anticipar y mitigar el abandono estudiantil.

Esta problemática adquiere mayor relevancia en un contexto post pandemia, donde las tasas de deserción han aumentado, afectando de manera desproporcionada a poblaciones vulnerables y exacerbando las brechas regionales. El tercer pilar del Plan Nacional de Desarrollo plantea la necesidad de implementar sistemas de alertas tempranas, pero su ejecución se ve obstaculizada por la falta de integración de datos socioeconómicos y académicos, así como por la ausencia de modelos analíticos robustos que permitan una intervención oportuna. En este escenario, el presente proyecto propone el desarrollo de un modelo predictivo de *machine learning*, capaz de clasificar el riesgo de deserción (bajo, medio, alto) a partir de variables como rendimiento académico, situación socioeconómica, apoyo financiero y características institucionales. La solución se enfocará en instituciones de educación superior, utilizando datos del SPADIES, DANE, ICFES e ICETEX, y buscará reducción de al menos un 5% en la tasa de deserción, optimizando la asignación de recursos y fortaleciendo la toma de decisiones basada en evidencia.

El proyecto se estructura en cinco fases interconectadas clave: inicialización, planificación, ejecución, control, y cierre. En la fase de inicialización, se definirán los criterios de éxito, la carta proyecto y los stakeholders involucrados, incluyendo al MEN, instituciones educativas, DANE y estudiantes. Durante la fase de planificación, se traducirá la problemática de negocio en un problema de *analytics*, identificando las fuentes de datos, realizando un análisis de riesgos (RBS) y estableciendo métricas de impacto, como la precisión del modelo ($\geq 80\%$), la tasa de retención por cohorte y la eficiencia en el uso de recursos públicos. La fase de ejecución abordará el preprocesamiento de datos, la selección de modelos (*Random Forest*, *XGBoost*, *regresión logística*, etc) y la generación de un dashboard interactivo para visualizar alertas tempranas. En la fase de control, se monitorea el desempeño del modelo, se validan las técnicas empleadas y se ajustan las estrategias según los resultados. Finalmente, en la fase de cierre, se presentarán los hallazgos en un informe técnico y un manual de implementación, asegurando la escalabilidad y sostenibilidad de la solución.

El beneficio esperado trasciende lo cuantitativo: además de reducir la deserción, el proyecto busca fortalecer la equidad educativa, mejorar la eficiencia institucional y generar conocimiento sobre los determinantes de la permanencia estudiantil. Las métricas de seguimiento incluirán la tasa de deserción semestral, la adopción institucional del modelo y la satisfacción de los usuarios finales ($\geq 85\%$). Este enfoque integral, alineado con los Objetivos de Desarrollo Sostenible (ODS) 4 y 10, no solo responderá a una necesidad inmediata del sistema educativo colombiano, sino que también sentará las bases para una cultura de analítica educativa, impulsando la transformación digital del sector y contribuyendo al desarrollo de políticas públicas más efectivas.

2. Estado del arte en las investigaciones del área

La deserción en la educación superior ha sido objeto de estudio en múltiples investigaciones a nivel nacional e

internacional, especialmente en los últimos cinco años, donde se ha observado un cambio de paradigma: desde enfoques descriptivos que buscan entender *qué pasó* hacia enfoques predictivos que anticipan *qué pasará*. Este cambio responde a la necesidad de implementar soluciones basadas en datos que permitan a las instituciones y gobiernos actuar de manera proactiva para reducir el abandono estudiantil. A continuación, se presentan los trabajos más relevantes que sustentan el enfoque metodológico, tecnológico y de negocio del presente proyecto, destacando su relación con los objetivos planteados.

a. José Leonardo Pérez Niño, Oscar Eduardo Gualdrón Guerrero, Diego José Barrera Oliveros. (2024- 2025). *SciELO*, Recuperado de: [Modelos de inteligencia artificial en minería de datos educativos para predecir la deserción](#)

El artículo "*Modelos de inteligencia artificial en minería de datos educativos para predecir la deserción*" (SciELO, 2024/2025) analiza la aplicación de técnicas de Inteligencia Artificial (IA) para anticipar riesgos de deserción en la educación superior. Este estudio destaca el uso de Árboles de Decisión (AD) y Bosques Aleatorios (Random Forest) como herramientas efectivas para clasificar a los estudiantes según su probabilidad de abandonar sus estudios. Los resultados demuestran que estos modelos permiten identificar patrones complejos en los datos, logrando una alta eficacia en la predicción de la deserción. Este hallazgo es fundamental para el presente proyecto, ya que valida la elección metodológica de emplear *Random Forest* o *XGBoost*, técnicas que han demostrado ser robustas en contextos similares. Además, el artículo subraya la importancia de integrar variables socioeconómicas y académicas, lo que refuerza la necesidad de utilizar fuentes de datos como SPADIES, DANE e ICFES para garantizar la precisión del modelo.

La relación con este proyecto es directa: confirma que el enfoque propuesto —desarrollar un modelo predictivo basado en IA— está alineado con las mejores prácticas internacionales, y que la combinación de técnicas de *machine learning* con datos institucionales puede generar alertas tempranas efectivas.

b. David Núñez Villalobos. (2025). Modelo Predictivo basado en Aprendizaje Automático para la Retención Estudiantil. *EPSIR*, Chile. Recuperado de: [Modelo Predictivo basado en Aprendizaje Automático para la retención Estudiantil](#)

El estudio "*Modelo Predictivo basado en Aprendizaje Automático para la Retención Estudiantil*" (EPSIR, 2025), desarrollado en Chile, propone un modelo de *machine learning* para evaluar la probabilidad de deserción en estudiantes de educación superior. Este trabajo emplea técnicas como Regresión Logística y Árboles de Decisión, identificando que variables como la "edad", el "apoyo psicológico" y la "situación laboral" son predictores clave del abandono académico. Estos hallazgos son especialmente relevantes para el contexto colombiano, donde factores similares —como el estrato socioeconómico, el acceso a becas y el rendimiento académico— han sido identificados como determinantes en informes como el de la Universidad Javeriana (2023).

El aporte de este estudio al presente proyecto es doble:

- Válida la inclusión de variables socioeconómicas (como la edad y la situación laboral) en el modelo predictivo, lo que garantiza que el análisis no solo se centre en aspectos académicos, sino también en el contexto social de los estudiantes.
- Destaca la importancia del "apoyo psicológico" como factor de retención, un aspecto que podría incorporarse en futuras iteraciones del modelo para enriquecer su capacidad predictiva.

Este trabajo refuerza la idea de que un modelo predictivo debe ser multidimensional, integrando no solo datos cuantitativos, sino también variables cualitativas que reflejen el entorno del estudiante.

c. Pontificia Universidad Javeriana. (2023). *Deserción en la educación superior en Colombia: Informe de resultados*. Bogotá, Colombia. Recuperado de: [Deserción en la educación superior en Colombia](#)

El informe "*Deserción en la educación superior en Colombia*" (Universidad Javeriana, 2023) sirve como punto de referencia crítico para este proyecto, ya que utiliza los mismos datos del SPADIES y emplea metodologías descriptivas y correlacionales para analizar el fenómeno. Entre sus hallazgos más relevantes, se destaca que:

- La deserción es mayor en hombres (13.4%) que en mujeres (11.9%).
- Existe una relación inversa entre el estrato socioeconómico y la deserción: a mayor estrato, menor probabilidad de abandono (del 13.3% en el estrato 1 al 7.1% en el estrato 6).

Estos resultados confirman la pertinencia de las variables seleccionadas para el modelo predictivo, como el género y el estrato socioeconómico, y validan el enfoque de segmentar el análisis por regiones y grupos poblacionales. Además, el informe subraya la necesidad de políticas diferenciadas según las características demográficas y socioeconómicas de los estudiantes, un principio que este proyecto adopta al proponer un análisis regionalizado (Orinoquía, Centro, Costa Caribe, etc.).

d. Pontificia Universidad Javeriana Cali. (2021). *Un enfoque predictivo con Machine Learning para mejorar la retención estudiantil*. Cali, Colombia. Recuperado de: [UN ENFOQUE PREDICTIVO CON MACHINE LEARNING PARA MEJORAR LA RETENCIÓN](#)

El estudio "*Un Enfoque Predictivo con Machine Learning para Mejorar la Retención*" (Universidad Javeriana Cali, 2021) comparte el objetivo central de este proyecto: generar alertas de riesgo de deserción mediante modelos de *machine learning*. Este trabajo emplea Regresión Logística y Bosques Aleatorios, demostrando que los resultados algorítmicos pueden traducirse en medidas preventivas concretas, como estrategias de apoyo personalizado para estudiantes en riesgo. Uno de sus aportes más significativos es la validación de que un score de probabilidad (en lugar de una clasificación binaria sí/no) permite a las instituciones priorizar intervenciones según el nivel de riesgo (bajo, medio, alto).

Este hallazgo es clave para el presente proyecto, ya que:

- Refuerza la decisión de implementar un modelo que clasifique a los estudiantes en niveles de riesgo, en lugar de limitarse a una predicción dicotómica.
- Demuestra la viabilidad de integrar los resultados del modelo en sistemas de información institucionales, facilitando la toma de decisiones basada en evidencia.

e. Universidad del Magdalena. (2025). *Sistema de predicción basado en machine learning de la deserción académica*. Santa Marta, Colombia. Recuperado de: [Sistema de predicción basado en machine learning de la deserción académica](#)

El estudio "*Sistema de Predicción Basado en Machine Learning de la Deserción Académica*" (Universidad del Magdalena, 2025) aborda la deserción desde una perspectiva multicausal, analizando factores sociales, económicos y académicos mediante modelos predictivos. Este trabajo destaca la importancia de que el modelo genere un score de probabilidad de deserción, en lugar de una simple clasificación binaria. Este enfoque permite a las instituciones segmentar a los estudiantes por niveles de riesgo y diseñar estrategias de intervención diferenciadas, lo que aumenta la efectividad de las acciones de retención.

Para este proyecto, este estudio es relevante porque:

- Valida el enfoque de utilizar un modelo que asigne probabilidades de deserción, lo que

- facilita la priorización de recursos y la implementación de estrategias focalizadas.
- Refuerza la necesidad de un sistema de alertas tempranas que sea dinámico y adaptable, capaz de ajustarse a cambios en el contexto socioeconómico o académico de los estudiantes.

Como se resume en la Tabla 1, los estudios previos sobre deserción en educación superior destacan el uso de técnicas como Random Forest y Regresión Logística, así como la relevancia de variables socioeconómicas (ej. estrato, apoyo psicológico) y académicas. Estos hallazgos validan la metodología propuesta en este proyecto, especialmente en lo relacionado con la selección de algoritmos y la inclusión de factores multicausales en el modelo predictivo.

Estudio	País/Año	Técnicas usadas	Variables clave	Hallazgos relevantes
"Modelos de IA en minería de datos educativos" (SciELO)	Colombia/2024	Random Forest, Árboles de Decisión	Rendimiento académico, apoyo financiero	Precisión del 88% en predicción de deserción.
"Modelo Predictivo para retención estudiantil" (EPSIR)	Chile/2025	Regresión Logística, Árboles de Decisión	Edad, apoyo psicológico, situación laboral	"Apoyo psicológico" como predictor clave.
"Deserción en educación superior" (U. Javeriana)	Colombia/2023	Análisis descriptivo/correlacional	Género, estrato socioeconómico	Mayor deserción en hombres (13.4%) vs. mujeres (11.9%).
"Enfoque predictivo con <i>machine learning</i> " (U. Javeriana Cali)	Colombia/2021	Random Forest, Regresión Logística	Variables académicas y socioeconómicas	Score de probabilidad > clasificación binaria.
"Sistema de predicción de deserción" (U. del Magdalena)	Colombia/2025	<i>Machine Learning</i> (XGBoost)	Factores multicausales (sociales, económicos, académicos)	Modelo con <i>score</i> de probabilidad para priorizar intervenciones.

Tabla 1. Resumen de estudios previos sobre deserción en educación superior. Fuente: Autoría propia.

Relación con el Proyecto Actual

Los estudios revisados validan cuatro aspectos fundamentales del presente proyecto:

- Fuentes de Datos:** Todos los trabajos coinciden en que el SPADIES, DANE e ICFES son las fuentes de información más confiables y completas para analizar la deserción en Colombia. Esto refuerza la decisión de utilizar estos datos como base para el modelo predictivo.
- Variables Clave:** Las investigaciones destacan que los factores socioeconómicos (estrato, situación laboral, edad) y académicos (rendimiento, apoyo psicológico) son los predictores más fuertes de la deserción. Esto confirma que las variables seleccionadas para el modelo son las adecuadas.
- Metodología:** El uso de Regresión Logística, Random Forest y XGBoost es recurrente en los estudios revisados, lo que respalda la elección de estas técnicas para el desarrollo del modelo. Además, se valida la importancia de incorporar métodos de explicabilidad (como *SHAP values*) para garantizar la transparencia y confianza en los resultados.
- Objetivo de Negocio:** Todos los trabajos coinciden en que el fin último de un modelo predictivo es generar alertas tempranas que permitan a las instituciones implementar estrategias de retención focalizadas. Esto alinea perfectamente con los objetivos del proyecto, que buscan no solo predecir la deserción, sino también facilitar la toma de decisiones basada en evidencia para reducirla.

El estado del arte demuestra que el proyecto propuesto está sólidamente fundamentado en investigaciones previas, tanto a nivel metodológico como en su enfoque de negocio. La combinación de técnicas de

machine learning, el uso de datos oficiales del SPADIES y DANE, y la generación de alertas tempranas basadas en niveles de riesgo representa una solución innovadora y viable para abordar la deserción en la educación superior colombiana. Además, los estudios revisados validan la factibilidad técnica del proyecto y subrayan su potencial impacto en la equidad educativa, la eficiencia institucional y la sostenibilidad del sistema de educación superior.

Este marco teórico no solo sustenta la metodología propuesta, sino que también proporciona lecciones aprendidas para evitar errores comunes, como la sobre-simplificación de las variables o la falta de explicabilidad en los modelos. En consecuencia, el proyecto está posicionado para contribuir significativamente a la reducción de la deserción y al fortalecimiento de las políticas públicas en el sector educativo.

3. Desarrollo del proyecto

El desarrollo del proyecto se estructura en fases secuenciales y complementarias, diseñadas para abordar la problemática de la deserción en la educación superior mediante una solución analítica concreta y medible. Cada etapa —desde la inicialización y planificación, pasando por la ejecución y control, hasta el cierre— integra metodologías de gestión de proyectos, técnicas de *analytics* y herramientas tecnológicas. Este enfoque garantiza que los resultados sean trazables, replicables y alineados con los objetivos estratégicos del Ministerio de Educación Nacional y las instituciones educativas. A continuación, se detallan las acciones, recursos y criterios de éxito asociados a cada fase, proporcionando un marco claro para la implementación y evaluación del modelo predictivo y su impacto en la reducción de la deserción.



Figura 1. Fases del proyecto: De la inicialización al cierre para reducir la deserción en educación superior.

Fuente: Autoría propia

3.1. Inicialización

La fase de Inicialización constituye el punto de partida estratégico del proyecto, donde se establecen los cimientos para el desarrollo de la solución analítica. En esta etapa, se formaliza la Carta del Proyecto (Project Charter), documento que integra la justificación del negocio, los objetivos estratégicos, los involucrados y, de manera crítica, los recursos y métricas de éxito que guiarán la ejecución.

Contexto y Planteamiento del Problema

El proyecto nace de una necesidad urgente del sistema educativo colombiano: la tasa de deserción en educación superior supera el **45%** (SPADIES, 2025). Esta cifra representa un obstáculo estructural para el cumplimiento del Plan Nacional de Desarrollo 2022-2026, el cual tiene una meta de gratuidad y cobertura del 62%, encontrándose actualmente rezagada en un 57%. La problemática no es solo académica, sino financiera: la deserción implica una pérdida ineficiente de recursos públicos invertidos en matrículas y subsidios que no culminan en la titulación del estudiante. Actualmente, la inexistencia de herramientas analíticas predictivas impide al Ministerio de Educación Nacional (MEN) y a las Instituciones de Educación Superior (IES) actuar de manera preventiva.

Alcance y Solución Propuesta

El alcance del proyecto comprende el diseño, desarrollo y despliegue de un **modelo predictivo de Machine Learning** integrado en un sistema de alertas tempranas. La solución clasificará a los estudiantes según su nivel de riesgo (Bajo, Medio, Alto) y proveerá un dashboard interactivo para la toma de decisiones. El proyecto se ejecutará en un plazo de dos semestres, abarcando desde la recolección de datos históricos (SPADIES, DANE, ICFES) hasta la validación del piloto en 21 instituciones seleccionadas.

Definición de Métricas de Éxito

Para garantizar un monitoreo integral, se han definido criterios de éxito en dos dimensiones, asegurando que el proyecto sea viable técnicamente y rentable para el negocio:

A. Métricas de Negocio (Impacto Estratégico):

- **Reducción de la Deserción:** Disminución de la tasa de deserción semestral en al menos un **5%** en las instituciones piloto tras el primer año de implementación de las alertas.
- **Eficiencia Financiera:** Optimización del gasto público mediante la retención de estudiantes subsidiados, proyectando un ahorro proporcional a las matrículas salvadas.
- **Adopción Institucional:** Lograr que el **100%** de las 21 instituciones piloto integren el sistema en sus procesos de bienestar universitario.

B. Métricas del Proyecto y Desempeño Técnico:

- **Precisión del Modelo:** Alcanzar un **AUC (Area Under the Curve) ≥ 0.85** y un **F1-Score ≥ 0.80** en la clase minoritaria (estudiantes que desertan), minimizando los falsos negativos.
- **Calidad de Datos:** Garantizar una completitud superior al **95%** en las variables críticas (estrato, puntaje Saber 11) tras el preprocesamiento.
- **Satisfacción del Usuario:** Obtener una calificación superior al **85%** en las encuestas de usabilidad del dashboard por parte de los administrativos de las IES.

Identificación de Recursos y Stakeholders

Para la ejecución exitosa, se han identificado y asegurado los siguientes recursos y actores clave:

- **Recursos Humanos:** El equipo estará conformado por un **Líder de Proyecto** (Gerencia y comunicación con stakeholders), un **Científico de Datos Senior** (Modelado y optimización), un **Ingeniero de Datos** (Integración ETL y calidad de datos) y un **Analista de BI** (Visualización y análisis de datos).
- **Recursos Tecnológicos:**
 - **Infraestructura:** Servicios en la nube (AWS/Azure) para el almacenamiento y procesamiento escalable de los datasets del SPADIES.
 - **Software de Modelado:** Lenguaje **Python** (librerías Scikit-learn, XGBoost, Pandas) para el desarrollo de los algoritmos.
 - **Visualización:** Licencias de **Power BI o Tableau** para el despliegue de los tableros de control interactivos.
- **Recursos de Datos:** Acceso a bases de datos históricas anonimizadas provistas por el **SPADIES** (histórico académico), **ICFES** (pruebas de estado) y **DANE** (contexto socioeconómico). Se contempla como limitante la latencia en la actualización de registros, mitigada mediante protocolos de carga batch semestral.
- **Stakeholders:**
 - **Sponsor:** Ministerio de Educación Nacional (MEN) - Subdirección de Desarrollo Sectorial.
 - **Usuarios Finales:** Directores de Bienestar Universitario y Planeación de las IES.

- **Proveedores de Información:** DANE e ICFES.

Esta estructuración formal en la fase de inicialización asegura la alineación entre la estrategia gubernamental y la ejecución técnica, mitigando riesgos desde el inicio y estableciendo una hoja de ruta clara para las fases subsiguientes de Planificación y Ejecución.

3.2 Fase Analizar y Diseñar: Planificación

Esta fase constituye el núcleo estratégico del proyecto, donde se traduce la gramática de negocio, una deserción superior al 45% (SPADIES, 2025) en un problema de analytics estructurado. El objetivo es desarrollar un modelo predictivo capaz de clasificar el riesgo de abandono (bajo, medio, alto) y generar alertas tempranas. Para ello, se han definido las bases técnicas, el análisis de riesgos y el aseguramiento de la calidad de los datos.

Análisis de Riesgos (RBS y AMEF)

La gestión de riesgos se estructuró mediante una Risk Breakdown Structure (RBS) para identificar amenazas en dimensiones técnicas, externas y de gestión. Posteriormente, se aplicó la metodología de Análisis de Modos y Efectos de Falla (AMEF) para cuantificar la criticidad de cada riesgo mediante el Número de Prioridad de Riesgo (NPR).

- **Riesgo Crítico (NPR: 240 - Alto):** Se identificó como el riesgo más severo el Retraso en la integración de datos debido a inconsistencias en llaves primarias entre SPADIES e ICFES.
 - **Estrategia de Mitigación:** Se ejecutará una Prueba de Concepto (PoC) de integración de datos en la semana 2 (Responsable: Ingeniero de Datos) para validar los joins y crear llaves subrogadas si es necesario antes de la carga masiva.
- **Riesgo Técnico (NPR: 180 - Medio/Alto):** Deriva del modelo (Model Drift) por cambios en políticas de becas o condiciones socioeconómicas.
 - **Estrategia de Mitigación:** Implementación de un pipeline de MLOps que monitoree mensualmente la distribución de variables de entrada y dispare reentrenamientos automáticos.
- **Riesgo de Adopción (NPR: 120 - Medio):** Resistencia al uso de la herramienta ("Caja Negra") por parte de las IES.
 - **Estrategia de Mitigación:** Uso de valores SHAP para explicar cada predicción y talleres de co-diseño con los usuarios finales.

Análisis de Datos y Dimensiones de Calidad

El análisis se fundamenta en fuentes oficiales (SPADIES, DANE, ICFES). Para garantizar que los datos sean aptos para el modelado, se realizó un perfilamiento exhaustivo evaluando cuatro dimensiones críticas de calidad:

1. **Totalidad:** Se verificó la completitud de los registros, identificando y tratando valores nulos en variables esenciales como Estrato Socioeconómico y Puntaje Saber 11, asegurando una completitud superior al 95% para el entrenamiento.
2. **Consistencia:** Se validó la coherencia lógica de los datos, cruzando las llaves de identificación entre las bases de SPADIES e ICFES para eliminar registros huérfanos y asegurar que la historia académica del estudiante sea trazable.
3. **Claridad:** Se estandarizaron los diccionarios de datos, unificando categorías ambiguas (ej. variaciones en nombres de programas académicos o ciudades) para evitar la dispersión de la información.
4. **Formato:** Se normalizaron todos los campos de fecha al estándar ISO 8601 y las variables numéricas al mismo sistema de unidades, garantizando la interoperabilidad entre las herramientas de Python y

SQL.

(Nota: Los scripts para el proceso de limpieza de datos se encuentran en el Anexo Técnico).

Cronograma y Asignación de Responsabilidades

El plan de trabajo se distribuye en 16 semanas, alineado con la metodología CRISP-DM, asignando responsables claros para garantizar la trazabilidad:

- **Fase Definir (Semanas 1-2):** Formalización del alcance, firma de Carta del Proyecto y validación con stakeholders.
 - **Responsable:** Líder del Proyecto / Sponsor (MEN).
- **Fase Medir (Semanas 3-5):** Ingesta de datos crudos (SPADIES, DANE), perfilamiento de calidad y establecimiento de línea base.
 - **Responsable:** Ingeniero de Datos.
- **Fase Analizar (Semanas 6-9):** Ingeniería de características (feature engineering), selección de variables y entrenamiento de modelos iterativos (Random Forest, XGBoost).
 - **Responsable:** Científico de Datos Senior.
- **Fase Mejorar e Implementar (Semanas 10-14):** Desarrollo del dashboard de alertas en Power BI, integración del modelo productivo y capacitación a usuarios.
 - **Responsable:** Desarrollador BI y Líder del Proyecto.
- **Fase Controlar (Semanas 15-16):** Monitoreo del despliegue, medición de KPIs de adopción y cierre del proyecto.
 - **Responsable:** Todo el equipo.

Enfoque de Modelación

La selección de técnicas predictivas responde a la naturaleza no lineal de los factores de deserción. Se priorizaron algoritmos de ensamble (Random Forest y XGBoost) por su robustez ante datos desbalanceados y su alta capacidad predictiva (validada en el estado del arte). Estos modelos se complementarán con técnicas de explicabilidad (SHAP Values) para ofrecer transparencia en las alertas generadas, permitiendo pasar de un enfoque puramente predictivo (qué pasará) a uno prescriptivo (qué hacer para evitarlo), facilitando así la intervención oportuna de las instituciones.

3.3. Fase Configuración y Construcción: Ejecución

La fase de Configuración y Construcción materializa el diseño analítico, transformando los datos crudos en una solución predictiva funcional. En esta etapa, se ejecutan las técnicas de modelado y se construye la infraestructura de visualización, asegurando la coherencia entre el problema de negocio (deserción) y la naturaleza técnica de los datos disponibles.

Selección y Justificación de Modelos y Técnicas

Dada la naturaleza de los datos provenientes del SPADIES e ICFES caracterizados por ser tabulares, con variables mixtas (categóricas y numéricas) y relaciones no lineales se seleccionaron técnicas de aprendizaje supervisado basadas en ensambles (*Ensemble Learning*). Específicamente, se implementarán **Random Forest** y **XGBoost**.

La elección de estas técnicas se justifica por tres factores críticos inherentes a los datos:

1. **Manejo de Desbalance de Clases:** La variable objetivo "Deserción" presenta una distribución desbalanceada (menos estudiantes desertan de los que permanecen). XGBoost permite ajustar los

pesos de las clases (*scale_pos_weight*) para penalizar los errores en la clase minoritaria, mejorando la sensibilidad del modelo.

2. **Robustez ante Ruido:** Random Forest reduce la varianza y el riesgo de sobreajuste (*overfitting*) al promediar múltiples árboles de decisión, lo cual es vital dado el ruido potencial en los registros históricos administrativos.
3. **Importancia de Variables:** Ambos algoritmos permiten extraer la importancia de los predictores (*feature importance*), facilitando la explicabilidad del fenómeno.

Procesamiento de Datos

La ejecución inicia con la aplicación de las técnicas de limpieza y transformación definidas en la fase de planificación:

- **Imputación:** Se aplicarán técnicas estadísticas (media/moda) o algoritmos como KNN para tratar valores nulos en variables socioeconómicas, preservando la **totalidad** de la muestra.
- **Codificación:** Transformación de variables categóricas (Ciudad, Programa) mediante *Target Encoding* o *One-Hot Encoding*, asegurando el **formato** numérico requerido por los algoritmos.
- **Ingeniería de Características:** Creación de nuevas variables explicativas, como el "Puntaje de Riesgo Financiero" (combinación de estrato y apoyo ICETEX), para enriquecer la capacidad predictiva.

Métricas de Ejecución como Insumo para Monitoreo y Control

Durante la construcción del modelo, se generarán métricas específicas que servirán como línea base e insumo directo para la fase de Monitoreo y Control (Sección 3.4). No solo se medirá la exactitud (*Accuracy*), sino que se priorizará:

- **F1-Score:** Será la métrica principal de desempeño técnico. Al ser la media armónica entre precisión y exhaustividad (*Recall*), esta métrica alimentará el sistema de control para detectar si el modelo pierde capacidad de identificar correctamente a los desertores reales.
- **PSI (Population Stability Index):** Se calculará el PSI inicial de las variables predictoras. Este valor servirá como referencia en la fase de operación para detectar *Data Drift* (cambios en la distribución de los datos) y disparar alertas de reentrenamiento.

Desarrollo del Dashboard de Alertas

La ejecución culmina con la integración del modelo en un **Dashboard Interactivo (Power BI/Tableau)**. Este entregable consumirá las probabilidades generadas por el modelo (Score 0-1) y las traducirá en semáforos de alerta (Rojo: Alta probabilidad, Amarillo: Media, Verde: Baja), permitiendo a los usuarios finales activar protocolos de retención focalizados en tiempo real.

3.4. Fase Operación, Optimización y Despliegue: Monitoreo y Control

Esta fase establece los mecanismos de vigilancia y ajuste necesarios para garantizar que la solución analítica mantenga su vigencia técnica y su relevancia de negocio a lo largo del tiempo. Se centra en la validación continua de los beneficios esperados y en la implementación de herramientas de control que operen en sinergia con la ejecución del modelo.

Sinergia entre Ejecución y Monitoreo

El proceso de Monitoreo y Control se alimenta directamente de las métricas generadas durante la fase de Ejecución (Sección 3.3). La sinergia se establece mediante un flujo de información bidireccional: el modelo en producción envía logs de desempeño (predicciones y datos reales) al sistema de monitoreo, y este, a su vez,

retroalimenta al modelo activando protocolos de reentrenamiento o calibración cuando se detectan desviaciones críticas. Este ciclo garantiza que el modelo no sea estático, sino que evolucione frente a cambios en el entorno educativo (ej. nuevas políticas de gratuidad).

Herramientas y Mecanismos de Control (El "Cómo")

Para llevar a cabo el control técnico y de negocio, se plantearán e implementarán las siguientes herramientas y procedimientos específicos:

1. Monitoreo Técnico (MLOps):

- **Herramienta:** Se implementará un pipeline de monitoreo automatizado utilizando herramientas como **MLflow** o scripts programados en Python (Airflow) que auditarán el modelo mensualmente.
- **Procedimiento:** Este sistema calculará automáticamente el **Population Stability Index (PSI)** comparando la distribución de los nuevos datos entrantes (SPADIES semestral) contra la línea base de entrenamiento.
- **Regla de Control:** Si el PSI supera el umbral de **0.2** (indicador de cambio significativo en la distribución) o si el **F1-Score** cae por debajo del **0.80**, el sistema disparará una alerta técnica al equipo de datos para iniciar una revisión de variables o un reentrenamiento supervisado.

2. Monitoreo de Negocio y Adopción:

- **Herramienta:** Se desplegará un módulo de administración dentro del **Dashboard (Power BI/Tableau)** exclusivo para los líderes del proyecto y el MEN.
- **Procedimiento:** Se rastrearán métricas de uso como la *Tasa de Apertura de Alertas* y el *Porcentaje de Estudiantes Intervenido*s.
- **Regla de Control:** Se validará trimestralmente si se está cumpliendo la meta de adopción en las 21 instituciones piloto. Una adopción inferior al 85% activará planes de re-capacitación y gestión del cambio con los usuarios finales.

Validación de Técnicas y Evaluación de Beneficios

Para confirmar que las técnicas empleadas (Random Forest/XGBoost) están generando el valor esperado, se realizará una validación cruzada *ex-post*:

- **Validación de Impacto:** Se comparará la tasa de deserción real de los estudiantes identificados como "Riesgo Alto" que recibieron intervención vs. un grupo de control (si es éticamente viable) o vs. la tasa histórica de la institución. El objetivo es confirmar la reducción neta del **5%** en la deserción prometida en la Carta del Proyecto.
- **Ajuste de Estrategias:** Si la validación evidencia que las alertas son precisas (técnicamente correctas) pero la deserción no disminuye, se ajustará la estrategia de intervención (la acción de negocio), no el modelo matemático, diferenciando así problemas de predicción de problemas de gestión.

Optimización y Cierre del Ciclo

Se establecen ventanas de mantenimiento semestrales coincidiendo con los cortes académicos. En estos periodos, se incorporarán nuevas variables explicativas derivadas de la retroalimentación cualitativa de las IES, asegurando la escalabilidad de la solución y la mejora continua del F1-Score y la confianza de los stakeholders.

3.5. Fase Cierre

La Fase de Cierre tiene como objetivo formalizar la finalización del proyecto, asegurando que los entregables sean aceptados por los stakeholders y que la solución analítica sea sostenible en el tiempo. Esta etapa se centra en la transferencia de conocimiento, la evaluación de la satisfacción y, crucialmente, en la validación de la coherencia entre el problema analítico planteado y la solución implementada.

Presentación de Resultados y Concordancia Analítica

Para garantizar la transparencia y la validación técnica, los resultados del modelo se presentarán y evaluarán mediante dos mecanismos complementarios:

1. **Informe de Cierre Técnico y de Negocio:** Se entregará un documento consolidado que contraste los hallazgos con los objetivos iniciales.
 - **Validación de Concordancia Analítica:** Se incluirá un capítulo específico dedicado a revisar la coherencia entre el **Enfoque Analítico** seleccionado en la fase de diseño (Aprendizaje Supervisado / Clasificación) y los resultados obtenidos. Se analizará si la elección de **Random Forest/XGBoost** fue la adecuada para manejar la no-linealidad de las variables socioeconómicas y si las métricas de desempeño (F1-Score) satisfacen los requerimientos de sensibilidad planteados inicialmente para la detección de desertores.
 - **Revisión de Requerimientos:** Se auditará el cumplimiento de los requerimientos funcionales (ej. latencia del dashboard < 5 seg) y de negocio (reducción de deserción), documentando cualquier desviación y su justificación.
2. **Sesión de Socialización (Project Close-out Meeting):** Una reunión formal con el Ministerio de Educación Nacional (Sponsor) y las IES piloto para presentar el impacto financiero (ahorros estimados) y social (estudiantes retenidos), buscando la firma del acta de aceptación final.

Procesos de Entrenamiento y Transferencia de Conocimiento

Para asegurar la adopción y la sostenibilidad operativa (que la solución no muera al finalizar el proyecto), se ejecutará un plan de capacitación diferenciado:

- **Entrenamiento Funcional (Usuarios Finales):** Talleres prácticos dirigidos a los Directores de Bienestar y Planeación de las IES. El objetivo es enseñarles a interpretar los semáforos de riesgo en el Dashboard, navegar por los filtros regionales y registrar las intervenciones realizadas. Se entregará un *Manual de Usuario* interactivo.
- **Entrenamiento Técnico (Equipo de TI/Datos):** Sesiones de transferencia de conocimiento ("Handover") dirigidas al equipo técnico que heredarán la herramienta. Se capacitará en la administración del pipeline de MLOps, la ejecución de scripts de reentrenamiento y la interpretación de logs de errores, asegurando que puedan mantener el modelo autónomamente.

Proceso de Implementación Final y Escalamiento

La transición del proyecto a la operación continua se realizará mediante:

- **Despliegue Final:** La migración definitiva del modelo y el dashboard a los servidores de producción del cliente (o la nube asignada), con pruebas de estrés finales para validar la concurrencia de usuarios.
- **Plan de Escalamiento:** Se entregará una hoja de ruta para expandir la solución de las 21 instituciones piloto a la totalidad del sistema de educación superior, detallando los requerimientos de infraestructura incremental necesarios.

Evaluación de Satisfacción de los Interesados

El éxito del proyecto no solo se medirá por métricas técnicas, sino por la percepción de valor de los usuarios. Se aplicará una encuesta de satisfacción (NPS y CSAT) a los stakeholders clave para evaluar:

1. La utilidad de las alertas tempranas en su gestión diaria.
2. La facilidad de uso de las herramientas entregadas.
3. La calidad de la gestión del proyecto (comunicación, tiempos).

Los resultados de esta evaluación, junto con las **Lecciones Aprendidas** (ej. dificultades en la integración de datos del ICFES), se documentará en el repositorio de activos de procesos de la organización para beneficiar futuros proyectos de analítica educativa.

4. Referencias

- Guerin, B. (s.f.). *Breaking the cycle of disadvantage: Early childhood interventions and progression to higher education in Europe*. Comisión Europea. Recuperado de http://europa.eu/epic/about/index_en.htm
- Ministerio de Educación Nacional. (2022). *Educación de calidad para vivir con dignidad: Apuestas del Plan Nacional de Desarrollo 2022-2026*. Recuperado de https://www.mineduacion.gov.co/1780/articles-415073_apuestas_plan_nacional_de_desarrollo_2022_2026.pdf
- Ministerio de Educación Nacional. (2025). *Información estadística de educación superior 2024: Cobertura educación*. Sistema Nacional de Información de la Educación Superior (SNIES). Recuperado de <https://snies.mineduacion.gov.co/portal//425163>
- Pontificia Universidad Javeriana. (2023). *Deserción en la educación superior en Colombia: Informe de resultados*. Bogotá, Colombia.
- Pontificia Universidad Javeriana Cali. (2021). *Un enfoque predictivo con Machine Learning para mejorar la retención estudiantil*. Cali, Colombia.
- Sistema para la Prevención de la Deserción de la Educación Superior (SPADIES). (2025). *Estadísticas de deserción escolar*. Ministerio de Educación Nacional. Recuperado de <https://www.mineduacion.gov.co/sistemasinfo/spadies/secciones/Estadisticas-de-desercion/>
- Universidad del Magdalena. (2025). *Sistema de predicción basado en machine learning de la deserción académica*. Santa Marta, Colombia.
- José Leonardo Pérez Niño, Oscar Eduardo Gualdrón Guerrero, Diego José Barrera Oliveros. (2025). Modelos de inteligencia artificial en minería de datos educativos para predecir la deserción. *SciELO*.
- David Núñez Villalobos. (2025). Modelo Predictivo basado en Aprendizaje Automático para la Retención Estudiantil. *EPSIR*, Chile.

ANEXOS