

Reporte de Implementación y Experimentos: Sistema de Alerta Temprana de Deserción en la Educación Superior

Proyecto Aplicado en Analítica de Datos (PAAD) - MIAD

Repositorio GitHub: [Link](#)

Grupo 10:

- CAROL JOHANA PEÑA PICO
- KEVIN SANCHEZ PRIETO
- JORGE ALBERTO GOMEZ VIGOYA
- ELIZABETH LORENA PORRAS ORTIZ

1. Requerimientos Analíticos y de Negocio

El presente proyecto aborda la problemática de la deserción en la educación superior en Colombia, un fenómeno con profundas implicaciones sociales y económicas. El objetivo principal es desarrollar un dashboard de alertas tempranas que permita identificar estudiantes en riesgo antes de que abandonen el sistema educativo.

Para cumplir con este objetivo, se integran los siguientes enfoques:

- **Analítica Descriptiva:** Identificación de patrones y perfiles sociodemográficos de desertores mediante el análisis de variables como el estrato, origen geográfico y rendimiento académico previo.
- **Analítica Predictiva:** Implementación de modelos de aprendizaje supervisado (clasificación) para estimar la probabilidad de deserción de un estudiante.
- **Integración Estratégica:** Los resultados del modelo se integran en un dashboard de alertas que clasifica los niveles de riesgo. Esto permite a usuarios y partes interesadas identificar factores clave, priorizar sus programas y ajustarlos o relanzarlos según los hallazgos.

2. Alternativas de Modelos y Técnicas

Debido a que el problema es de naturaleza binaria, se evaluaron las siguientes alternativas técnicas:

Modelo	Ventajas	Desventajas
Regresión Logística	Alta interpretabilidad permitiendo entender el impacto directo de cada variable (odds ratios).	Al asumir linealidad puede ser limitada para capturar interacciones complejas entre variables.
Random Forest	Excelente manejo de variables no lineales y outliers. Reduce el sobreajuste mediante ensamble.	Mayor consumo de memoria y es menos interpretable que un modelo lineal simple.
XGBoost	Rendimiento superior en datos tabulares. Realiza manejo	Requiere un proceso de ajuste de hiper parámetros más exhaustivo y

Modelo	Ventajas	Desventajas
	eficiente de datos faltantes y regularización integrada.	un alto costo computacional. Presenta riesgo de overfitting.

3. Verificación de Supuestos y Tratamiento de Datos

El conjunto de datos se obtuvo de SPADIES, sistema en el cual cada institución de educación superior (IES) registrada reporta información sobre deserción, junto con características asociadas a la institución, al estudiante y a los programas académicos.

El dataset comprende 31.567 registros y 25 variables, con información a nivel nacional, lo que permite analizar patrones de deserción y los factores relacionados con este fenómeno.

3.1. Diccionario de Datos:

Variable	Descripción	Tipo Dato	Valores Únicos	Ejemplos
id_estudiante	Identificador único del estudiante	Numérico	31567	20, 19, 18
anio_registro	Año de ingreso o registro del dato	Numérico	6	2018, 2019, 2020
sexo	Género del estudiante	Texto	2	Hombre, Mujer
edad_ingreso	Edad al momento de ingresar a la educación superior	Numérico	18	20, 22, 21
estado_civil	Estado civil reportado	Texto	4	Unión libre, Soltero, Casado
zona_residencia	Ubicación geográfica de la vivienda (Urbana/Rural)	Texto	2	Urbana, Rural
departamento	Departamento de residencia en Colombia	Texto	27	Tolima, Valle del Cauca, Nariño

Variable	Descripción	Tipo Dato	Valores Únicos	Ejemplos
estrato_socioeconomico	Nivel socioeconómico según servicios públicos (1-6)	Numérico	6	3, 1, 4
trabaja_mientras_estudia	Indica si tiene ocupación laboral (1: Sí, 0: No)	Booleano	2	1, 0
beneficiario_icetex	Indica si financia estudios con ICETEX (1: Sí, 0: No)	Booleano	2	0, 1
beneficiario_beca	Indica si cuenta con algún tipo de beca (1: Sí, 0: No)	Booleano	2	1, 0
nivel_educativo_padre	Máximo nivel educativo alcanzado por el padre	Texto	6	Posgrado, Primaria, Universitario
nivel_educativo_madre	Máximo nivel educativo alcanzado por la madre	Texto	6	Primaria, Bachillerato, Tecnico
sector_ies	Tipo de institución de educación superior	Texto	2	Público, Privado
nivel_formacion	Nivel del programa académico	Texto	3	Técnico profesional, Universitario, Tecnológico
metodologia	Modalidad de estudio	Texto	3	Presencial, Distancia tradicional, Virtual
area_conocimiento	Área disciplinar del programa	Texto	8	Economía, administración,

Variable	Descripción	Tipo Dato	Valores Únicos	Ejemplos
				contaduría y afines, Matemáticas y ciencias naturales, Ciencias de la salud
semestre_cursado	Último semestre completado o en curso	Numérico	10	3, 1, 2
promedio_academico	Calificación promedio acumulada (0.0 - 5.0)	Numérico	400	1.85, 4.29, 2.75
creditos_aprobados	Cantidad total de créditos académicos superados	Numérico	161	40, 43, 15
materias_reprobadas	Total de asignaturas no aprobadas en la carrera	Numérico	9	1, 2, 4
doble_jornada	Indica si el estudiante estudia en horario extendido	Booleano	2	0, 1
distancia_hogares_km	Distancia física entre el hogar y la universidad	Numérico	5104	6.76, 4.43, 1.77
puntaje_icfes_percentil	Percentil obtenido en la prueba Saber 11	Numérico	100	74, 55, 69
desercion	Variable objetivo (1: Desertó, 0: No desertó)	Booleano	2	1, 0


Se realizaron los siguientes tratamientos de preparación:

- **Validación de nulos y duplicados:** Se validan y eliminan los valores sin información o categorías que no aportan al desarrollo del ejercicio.
- **Codificación Categórica:** Uso de OneHotEncoder para variables como departamento, estado civil, sexo y zona de residencia, evitando introducir un orden artificial en los datos.
- **Normalización:** Aplicación de StandardScaler a variables numéricas (promedio académico, materias reprobadas, puntaje ICES) para asegurar que todas las características tengan la misma escala.
- **Tratamiento de Desbalance:** Se emplearon técnicas de validación estratificada para asegurar que el modelo aprenda adecuadamente de la clase minoritaria.

3.2. Análisis univariado

La tasa promedio de deserción del conjunto de datos es del 28%. La caracterización de los estudiantes es la siguiente: la edad promedio de ingreso es de 19 años, pertenecen principalmente a estratos medio-bajos (promedio 2.6) y presentan un promedio académico acumulado de 3,1 sobre 5. En cuanto a su trayectoria, han cursado en promedio 3.8 semestres, lo que indica que muchas observaciones se concentran en etapas iniciales de las carreras. El percentil promedio en la prueba Saber 11 es 45, lo que sugiere un nivel académico medio al ingreso. Respecto a las condiciones de apoyo, el 18% cuenta con crédito del ICETEX, mientras que el 12% tiene algún tipo de beca. Además, el 35% de los estudiantes trabaja mientras estudia.

La información abarca registros entre 2018 y 2023. Se identifican algunos valores atípicos en variables como la edad (con casos superiores a los 30 años), el número de materias reprobadas y la distancia entre el lugar de residencia y la institución. No obstante, estos casos son poco frecuentes, por lo que no se realizó un tratamiento diferenciado para estos. En variables categóricas, se observa una mayor proporción de mujeres, predominan estudiantes solteros y de zonas urbanas. La mayor concentración de instituciones se encuentra en Bogotá y Antioquia. En cuanto al nivel educativo de los padres, es más frecuente el bachillerato como máximo nivel alcanzado. Finalmente, la mayoría de los registros corresponde a programas universitarios presenciales, especialmente en áreas de ingeniería, arquitectura, urbanismo y afines.




3.2.1. Relaciones entre variables

En cuanto al comportamiento entre variables, se observan algunas diferencias relevantes como que los estudiantes que trabajan tienden a reprobado un mayor número de materias, al

igual que aquellos que cursan en jornada extendida. Esto sugiere posibles restricciones de tiempo que podrían afectar su desempeño académico.

Por otro lado, la matriz de correlación muestra niveles generalmente bajos o moderados entre las variables numéricas, lo que es adecuado para el análisis. La principal excepción es la relación entre el número de créditos aprobados y semestre cursado, que presenta una alta correlación, algo esperable dado que ambas variables capturan el avance académico del estudiante. En este sentido, estas variables deben tratarse con cautela en la estimación de modelos, ya que pueden introducir problemas de multicolinealidad o redundancia de información.




3.3. Análisis bivariado

En los biplots se evidencia que los estudiantes que desertan tienden a concentrarse en edades ligeramente superiores frente a quienes no lo hacen, pertenecen principalmente a estratos por debajo del 3 y abandonan en semestres iniciales, además de registrar promedios académicos un poco más bajos. En cuanto a los puntajes de Saber 11, no se observan diferencias claras entre quienes desertan y quienes continúan, lo que sugiere que el fenómeno no está determinado únicamente por el nivel académico con el que se egresa del colegio.

Al analizar proporciones, los estudiantes que trabajan mientras estudian presentan una tasa de deserción ligeramente mayor, al igual que quienes cursan en jornada extendida, probablemente porque ambos grupos comparten condiciones de menor disponibilidad de tiempo. En contraste, quienes reciben apoyo financiero a través de becas o del ICETEX no muestran diferencias marcadas en la tasa de deserción frente al resto, lo que sugiere que estos apoyos, al menos en este conjunto de datos, no son un factor diferenciador claro.

En conjunto, los resultados apuntan a que la deserción está más asociada a factores de desempeño académico y condiciones socioeconómicas, especialmente en las primeras etapas de la trayectoria universitaria, mientras que variables como el nivel académico previo o el acceso a financiamiento no parecen por sí solas explicar el abandono.



4. Entrenamiento, Validación y Métricas

El proceso experimental se diseñó de manera rigurosa, con el objetivo de seleccionar, entre las alternativas planteadas, un modelo que cumpliera con los requerimientos definidos, enfocados en esta etapa principalmente en el desempeño. Se evaluaron modelos de regresión logística, Random Forest y XGBoost, destacándose los siguientes aspectos:

- **Esquema de Validación:** Se utilizó una partición de 80/20 en los sets de train y test combinada con Cross-Validation estratificada para garantizar la estabilidad de los resultados.
- **Optimización:** Se implementó Optuna para la búsqueda de hiper parámetros óptimos, maximizando el desempeño del modelo XGBoost.
- **Selección de Variables:** Mediante RFECV (Eliminación Recursiva de Características con Validación Cruzada), se identificaron las 15 variables con mayor poder predictivo, optimizando la eficiencia del modelo.

4.1. Justificación de métricas:

En este contexto, un falso negativo (no identificar a un estudiante con riesgo de deserción) tiene un costo mayor que un falso positivo. Por esta razón, se prioriza el recall, ya que mide la capacidad del modelo para detectar la mayor cantidad posible de casos reales de deserción. De forma complementaria, se utiliza el F1-score, que equilibra el recall con precisión y permite controlar el número de falsas alarmas. El accuracy se considera, pero no es la métrica principal, dado que puede resultar engañosa en presencia de desbalance de clases. Finalmente, se incorpora el AUC-ROC para evaluar la capacidad del modelo de discriminar entre estudiantes que desertan y los que no, independientemente del umbral de decisión.

5. Análisis de los modelos probados

Como se ha mencionado anteriormente se han probado 3 modelos, de los cuales, se tienen los siguientes resultados:

- **Regresión Logística**

===== REPORTE =====					
	precision	recall	f1-score	support	
0	0.91	0.80	0.85	4501	
1	0.61	0.80	0.70	1813	
accuracy			0.80	6314	
macro avg	0.76	0.80	0.77	6314	
weighted avg	0.82	0.80	0.81	6314	

El modelo de regresión logística muestra un desempeño global aceptable con una exactitud de 0.80 y un F1 ponderado de 0.81. Se observa un buen equilibrio en el recall (0.80 para ambas clases), lo que indica que logra identificar una proporción similar de positivos y negativos. Sin embargo, la precisión para la clase 1 (0.61) es considerablemente más baja, lo que sugiere una mayor tasa de falsos positivos en esta clase. En general, es un modelo estable y fácil de interpretar, pero con limitaciones para discriminar correctamente la clase minoritaria en términos de precisión.

- **Random Forest**

	precision	recall	f1-score	support	
0	0.90	0.82	0.86	4501	
1	0.64	0.78	0.70	1813	
accuracy			0.81	6314	
macro avg	0.77	0.80	0.78	6314	
weighted avg	0.82	0.81	0.81	6314	

El modelo de Random Forest presenta una ligera mejora respecto a la regresión logística, alcanzando una exactitud de 0.81 y manteniendo un F1 ponderado de 0.81. La precisión de la clase 1 mejora (0.64) sin sacrificar significativamente el recall (0.78), lo que indica un mejor balance entre falsos positivos y falsos negativos. Además, el desempeño en la clase 0 también mejora levemente. Este modelo captura relaciones no lineales y suele ser más robusto que la regresión logística, aunque aún presenta ciertas limitaciones en la discriminación de la clase minoritaria.

- **XGboost**

	precision	recall	f1-score	support	
0	0.87	0.92	0.89	4501	
1	0.76	0.65	0.70	1813	
accuracy			0.84	6314	
macro avg	0.81	0.78	0.80	6314	
weighted avg	0.84	0.84	0.84	6314	

El modelo XGBoost es el que presenta el mejor desempeño global, con una exactitud de 0.84 y un F1 ponderado de 0.84. Destaca por una mejora significativa en la precisión de la clase 1 (0.76), lo que reduce los falsos positivos, aunque con una leve disminución en el recall

(0.65). Esto evidencia un trade-off entre precisión y recall, favoreciendo un modelo más conservador al momento de clasificar la clase positiva, lo cual puede ser deseable en escenarios donde los falsos positivos tienen un mayor costo.

Adicionalmente, logra un excelente desempeño en la clase 0 (F1 de 0.89). La diferencia entre el F1-score macro (0.80) y el ponderado (0.84) sugiere que el modelo presenta un mejor desempeño en la clase mayoritaria, lo cual es consistente con la distribución desbalanceada del dataset.

El mejor desempeño de XGBoost puede explicarse por su capacidad de optimizar errores de manera secuencial mediante boosting, capturando patrones complejos que modelos como la regresión logística no logran modelar y que Random Forest no prioriza de forma iterativa. Asimismo, la estabilidad observada tanto en el tiempo como en la importancia de las variables sugiere una mejor capacidad de generalización y menor riesgo de sobreajuste.

En conjunto, aunque los tres modelos presentan desempeños competitivos, XGBoost se posiciona como la mejor alternativa debido a su mayor exactitud, mejor balance global medido a través del F1-score y, especialmente, su mayor estabilidad en la importancia de variables. Esta consistencia es clave en contextos productivos, donde la robustez temporal y la confiabilidad del modelo son factores determinantes para su implementación.

6. Análisis de Resultados y Ajustes

Los experimentos revelaron que el rendimiento académico es el predictor más fuerte. A continuación, se detallan los hallazgos principales:

- **Variables Críticas:** El *promedio_academico* (importancia de 0.26) y las *materias_reprobadas* (0.09) son los factores determinantes.
- **Factores Socioeconómicos:** Variables como *estrato_socioeconomico* y *beneficiario_beca* mostraron una correlación significativa con la permanencia.
- **Ajustes Realizados:** Se ajustó el umbral de decisión (threshold) del modelo a 0.4 para aumentar la sensibilidad del sistema de alertas, permitiendo capturar un mayor porcentaje de estudiantes en riesgo.

7. Plan de Implementación del Prototipo

Para la fase final, se han identificado los siguientes componentes pendientes de desarrollo:

1. **Empaquetamiento del Modelo:** Exportación de los pipelines de preprocesamiento y el modelo final en formato joblib para su despliegue.
2. **Interfaz de Usuario (Dashboard):** Desarrollo de un tablero en Streamlit que permita cargar datos de nuevos estudiantes y visualizar el nivel de riesgo en un semáforo (Rojo/Amarillo/Verde).
3. **Módulo de Reportes:** Generación automatizada de archivos PDF con el listado de estudiantes priorizados para intervención inmediata.
4. **Plan de Evaluación:** Pruebas piloto con una cohorte real de datos para validar la precisión de las alertas generadas.